

Università degli Studi di Genova

Dipartimento di informatica, bioingegneria, robotica e ingegneria dei sistemi - DIBRIS

Corso di Studio in Ingegneria Informatica

Tesi di Laurea Triennale

Ottobre 2026

Random Forest come sviluppo del Decision Tree: introduzione al modello e applicazione alla predizione del degrado gomme in Formula 1

Relatore:
Prof. Luca Calatroni

Candidato:
Giulia Righi

Anno Accademico 2025/2026

Indice

1 Introduzione **2**
- 1.1 Motivazione e obiettivi . . . 2
- 1.2 Struttura della tesi . . . 3

2 La Formula 1 come sistema ingegneristico **4**
- 2.1 Monoposto e i suoi componenti . . . 4
- 2.2 Le forze in gioco . . . 5
- 2.3 Gomme: struttura e mescole . . . 7
- 2.4 Il degrado delle gomme . . . 8

3 Random Forest: dal Decision Tree al modello ensemble **10**
- 3.1 Decision Tree nel caso unidimensionale . . . 11
- 3.2 Estensione al caso multidimensionale . . . 13
- 3.3 Limiti del Decision Tree singolo . . . 15
- 3.4 Bagging (Bootstrap Aggregating) . . . 16
- 3.5 Random Forest . . . 20
- 3.6 Feature importance . . . 22

4 Dati e metodologia **23**
- 4.1 Libreria FastF1 e creazione del dataset . . . 23
- 4.2 Costruzione della variabile target . . . 24
- 4.3 Divisione training set e test set . . . 24
- 4.4 Analisi statistica preliminare . . . 25
- 4.5 Modelli a confronto e validazione . . . 26

5 Risultati **28**
- 5.1 Performance dei modelli . . . 28
- 5.2 Valutazione sul Test Set . . . 29
- 5.3 Interpretazione dei risultati . . . 31

6 Conclusioni **33**
- 6.1 Sintesi dei risultati . . . 33
- 6.2 Sviluppi futuri . . . 34

Capitolo 1

Introduzione

1.1 Motivazione e obiettivi

La **Formula 1** (F1) è il campionato mondiale più famoso di auto da corsa organizzato dalla Federazione Internazionale dell'Automobile (FIA). Ogni anno la stagione è strutturata in un calendario di Gran Premi distribuiti nel corso dell'anno e disputati su diversi circuiti internazionali. Ciascun evento si svolge durante il fine settimana e comprende sessioni di prove libere, qualifiche e gara.

Alla competizione prendono parte diverse squadre (scuderie) in qualità di costruttori, con l'obiettivo di progettare e sviluppare la propria monoposto rispettando i vincoli imposti dal regolamento tecnico e sportivo emanato dalla FIA[6]. Ogni team ha due piloti, i quali competono sia per il Campionato Piloti sia per il Campionato Costruttori, combinando il risultato del singolo pilota alle strategie collettive del team.

Durante un weekend di gara viene raccolta un'ampia quantità di dati che vanno dalle prestazioni meccaniche e aerodinamiche della vettura, alla gestione delle strategie, fino alle variabili ambientali e al rendimento dei piloti, consentendo un'analisi completa e indispensabile per lo sviluppo e le strategie della squadra.

Il degrado delle gomme è uno dei fattori che più influenzano la strategia di gara. Dipende da molte variabili, tra cui circuito e mescola, ma anche dall'assetto aerodinamico della vettura, che influisce sul carico verticale delle gomme. Non essendo il carico aerodinamico direttamente misurabile dai dati pubblici, lo si può stimare dalle velocità registrate allo speed trap e nei settori intermedi, perchè a parità di potenza più carico significa più resistenza e quindi velocità più basse.

La stima si basa sui dati delle qualifiche, momento in cui entra in vigore il regime di *Parco Chiuso*, per cui l'assetto della vettura non può essere modificato in modo sostanziale.

L'obiettivo del lavoro è rispondere al seguente quesito: *le velocità registrate in qualifica, utilizzate come proxy del carico aerodinamico, permettono di prevedere se uno stint di gara presenterà degrado delle gomme alto o basso rispetto alla mediana del circuito e della mescola?*

1.2 Struttura della tesi

L'analisi si sviluppa a partire dal contesto ingegneristico di una monoposto, esaminando le forze in gioco, il ruolo fondamentale delle gomme e le cause del loro degrado. Si introducono poi gli strumenti di classificazione, dal Decision Tree fino al Random Forest. Questi modelli vengono applicati ai dati di qualifica e di gara delle stagioni dal 2022 al 2025, descrivendo come è costruito il dataset e come vengono confrontati i modelli. Si discutono infine i risultati ottenuti.



Figura 1.1: Gran Premio dell'Austria 2026. Fonte: archivio dell'autore.

Capitolo 2

La Formula 1 come sistema ingegneristico

L'analisi si sviluppa a partire dal quadro ingegneristico della vettura. Una monoposto di Formula 1 costituisce un **sistema complesso** in cui la prestazione nasce dal perfetto equilibrio tra i suoi componenti. Tra questi, **le gomme** rappresentano l'unico punto di contatto con l'asfalto, tramite il quale si generano le **forze longitudinali e trasversali** fondamentali per l'accelerazione, la frenata e la tenuta in curva.

Questo studio fa riferimento al regolamento tecnico FIA 2022-2025[6].

2.1 Monoposto e i suoi componenti

Per comprendere la cinematica e la dinamica del veicolo, occorre esaminare i componenti meccanici chiave. L'efficienza della monoposto è determinata dal perfetto bilanciamento di quattro macro-sistemi fondamentali (Figura 2.1):

- **Telaio**: è la struttura portante realizzata in fibra di carbonio (*monoscocca*) a cui sono fissati tutti i componenti meccanici, inoltre protegge il pilota (*survival cell*) dagli urti.
- **Aerodinamica**: è l'insieme degli elementi (ali, fondo, diffusore e pance), che gestiscono il flusso d'aria. La sua funzione è generare una spinta verso il basso (*downforce*) per migliorare la tenuta in curva, riducendo il più possibile la resistenza aerodinamica (*drag*) nei tratti ad alta velocità.
- **Power Unit**: è l'unità che fornisce spinta alla vettura grazie al lavoro del motore termico V6 turbo e della parte elettrica, che riutilizza l'energia recuperata in frenata e dai gas di scarico.
- **Sospensioni**: collegano le ruote al telaio (con schema *push-rod* o *pull-rod*) e controllano i movimenti della vettura in accelerazione, frenata e curva, tenendo stabile l'altezza del fondo e massimizzando l'aderenza (*grip*) delle gomme con l'asfalto.

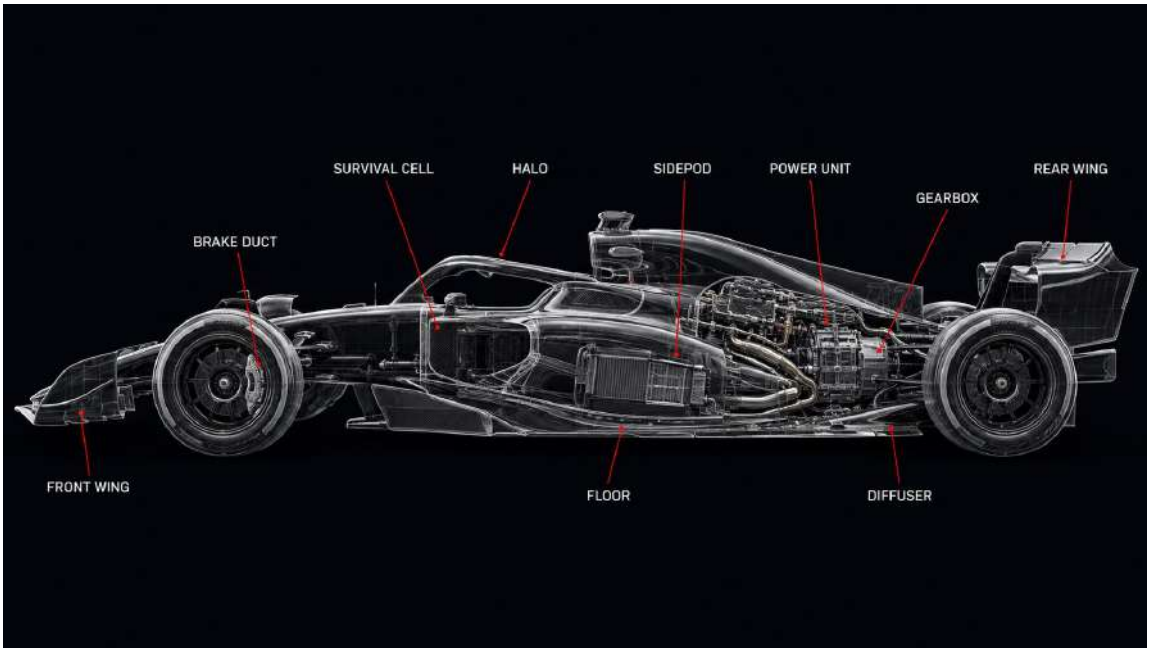


Figura 2.1: Anatomia di una monoposto di Formula 1. Fonte: [8]

L'azione combinata di questi sistemi si traduce, in pista, in un insieme di forze che agiscono sulla monoposto.

2.2 Le forze in gioco

La prima forza considerata è la **forza peso**, responsabile del contatto tra il veicolo e il suolo, si definisce come:

$$F_g = m\,g \tag{2.1}$$

dove m è la massa della vettura e g l'accelerazione di gravità.

La seconda categoria è costituita dalle forze generate dal flusso d'aria che colpisce la monoposto. L'inclinazione e la forma di ali, fondo e diffusore sono studiate per spingere la vettura verso il basso, il principio è lo stesso dell'ala di un aereo, ma capovolto. Questo effetto si chiama **deportanza** (*downforce*) e permette alle gomme di aderire meglio alla pista. L'aria, però, ostacola anche l'avanzamento della vettura e questo genera inevitabilmente anche una forza frenante, la **resistenza aerodinamica** (*drag*). Le due forze sono rappresentate in Figura 2.2.

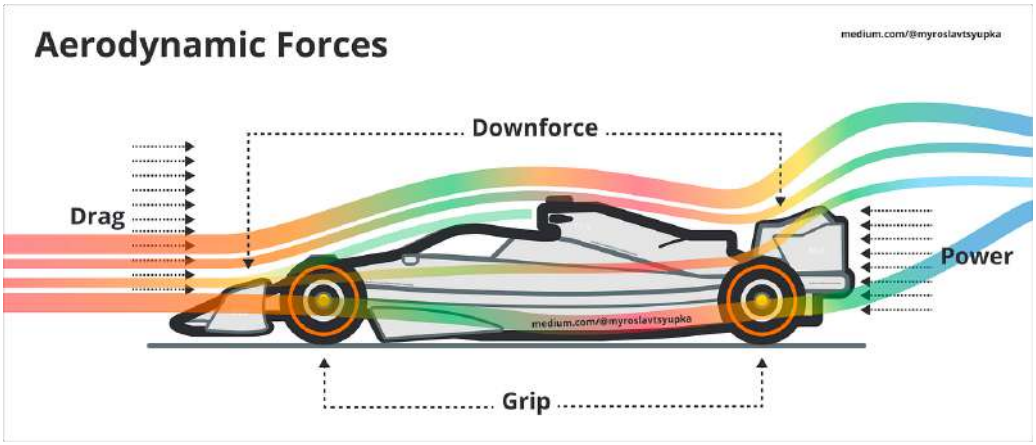


Figura 2.2: Forze aerodinamiche di una monoposto di Formula 1. Fonte: [3].

Le relazioni fondamentali che governano queste due forze aerodinamiche sono:

$$F_{z,aero} = \tfrac{1}{2}\,\rho\, C_L\, A\, v^2, \qquad F_D = \tfrac{1}{2}\,\rho\, C_D\, A\, v^2, \tag{2.2}$$

dove ρ è la densità dell'aria, v è la velocità della vettura, A è la superficie di riferimento, mentre C_L e C_D sono i coefficienti aerodinamici (rispettivamente di deportanza e di resistenza) che descrivono l'efficienza della forma geometrica del veicolo. Il rapporto tra deportanza e resistenza (C_L/C_D) indica l'efficienza aerodinamica del veicolo.

Per modificare la traiettoria o la velocità di un'automobile serve una forza che la vettura può ottenere unicamente dall'aderenza delle ruote sull'asfalto. Questa forza si divide in due componenti: una **longitudinale** (F_x), che agisce lungo il senso di marcia (accelerazione e frenata), e una **trasversale** (F_y) necessaria per affrontare le curve.

Queste forze sono vincolate da un limite superiore (*upper bound*), definito dalle condizioni di aderenza μ e proporzionale alla somma tra forza peso e deportanza, detto anche **carico verticale** N:

$$\sqrt{F_x^2 + F_y^2} \leq \mu\ N \tag{2.3}$$

Tale vincolo, detto **cerchio di aderenza**, evidenzia come la ruota ha una capacità limitata: se viene sfruttata interamente per frenare non resta aderenza per curvare, e viceversa.

In condizioni reali, però, il coefficiente μ non è un parametro costante, ma dipende dal carico verticale, dalla temperatura e dallo stato di usura della gomma[9]. Questa progressiva perdita di aderenza costituisce il **degrado** dello pneumatico.

Tutte le forze descritte si trasmettono attraverso la ruota, di conseguenza risulta indispensabile approfondire le proprietà e il comportamento della gomma.

2.3 Gomme: struttura e mescole

Il pneumatico è una struttura formata da tre elementi principali: la **carcassa**, che ne determina la forma e assorbe i carichi strutturali; la **cintura**, che stabilizza l'intera struttura e aiuta a contrastare gli effetti della forza centrifuga, dovuta alla rotazione della ruota; il **battistrada**, che rappresenta il punto di contatto tra lo strato di gomma e l'asfalto, e il suo comportamento dipende dalla **mescola** con cui è realizzato[9].

La mescola è un materiale che nasce dall'unione di gomme e additivi per bilanciare grip e durata. Una *mescola morbida* garantisce maggiore aderenza, ma usura più rapidamente, mentre una *mescola dura* offre una durata maggiore, ma meno aderenza.

Dal 2011 **Pirelli** è l'unico fornitore di pneumatici per la Formula 1, secondo le direttive stabilite dai regolamenti della FIA. Per ogni Gran Premio, tutte le squadre utilizzano le stesse gomme. Pirelli seleziona tre mescole da asciutto (*soft, medium, hard*) e due per il bagnato (*intermediate, full wet*)[12], come mostrato in Figura 2.3.


PIRELLI
PIRELLI
PIRELLI

Ogni mescola offre la massima aderenza solo all'interno della propria finestra di temperatura ideale. Se la gomma rimane fredda non garantisce abbastanza grip, mentre se si surriscalda perde efficacia e si usura rapidamente. Si torna così al problema principale: il **degrado**.

2.4 Il degrado delle gomme

Come definito in precedenza, il degrado è la progressiva perdita di aderenza del pneumatico durante l'utilizzo, caratterizzata da usura fisica e fenomeni termici/strutturali.

Il fenomeno più comune è l'usura per attrito tra il battistrada e l'asfalto che genera un rilascio continuo di frammenti di gomma. Quando si depositano lungo la traiettoria ideale, questi residui migliorano il grip (*rigommatura*), mentre quando finiscono ai lati del tracciato si accumulano formando dei pallini di gomma (*marbles*) che rendono l'asfalto scivoloso provocando una perdita di aderenza e quindi anche di prestazioni.

Se la temperatura si discosta dalla finestra ottimale della mescola, si possono verificare due fenomeni di degrado:

- **graining**: si verifica quando la mescola è troppo fredda. Il battistrada tende a strapparsi, formando piccoli granuli di gomma che rimangono comunque attaccati alla superficie. La finitura del battistrada diventa rugosa, riducendo la superficie di contatto con l'asfalto. Questo effetto tende a regredire man mano che la mescola raggiunge la giusta temperatura (Figura: 2.4);
- **blistering**: è causata da eccessivo surriscaldamento interno della mescola. Porta alla formazione di bolle d'aria all'interno del battistrada, che si rompono strappando porzioni di gomma, causando una perdita improvvisa di aderenza e prestazioni.



Figura 2.4: L'impatto del graining sulle slick. Fonte: [17].

Qualunque sia la sua forma, il degrado impone ad ogni team una scelta strategica fondamentale. Pneumatici nuovi garantiscono più aderenza, ma il tempo perso al *pit-stop* potrebbe far perdere posizioni cruciali per la vittoria. Prevedere con esattezza la resa di una mescola e individuare il momento perfetto per sostituirla costituisce un aspetto importante per il successo della gara. A questa componente dinamica si aggiunge il vincolo regolamentare che, nelle gare con pista asciutta, impone di utilizzare almeno due mescole diverse, rendendo obbligatoria almeno una sosta al box [6]. Per tali ragioni, l'analisi del degrado rappresenta uno dei principali ambiti di studio per gli ingegneri di pista.

Capitolo 3

Random Forest: dal Decision Tree al modello ensemble

L'obiettivo primario della *data science* e del *machine learning* è la predizione: estrapolare **informazioni** dai dati disponibili per stimare misurazioni non ancora osservate. Una previsione, però, non basta enunciarla, va anche giustificata. Per fare questo si utilizza la teoria della probabilità, che fornisce gli strumenti per descrivere l'incertezza e stimare dati futuri a partire da quelli passati. Il punto di partenza è considerare i nostri dati come esiti di un fenomeno aleatorio.

Questa decisione si giustifica su due livelli. In primo luogo, ipotizzare che i dati derivino da un meccanismo aleatorio, significa presupporre l'esistenza di un processo che li produce: questo giustifica l'idea che i dati passati possano offrire informazioni utili su quelli futuri. In secondo luogo, questa assunzione cattura naturalmente le incertezze di qualsiasi misura: molti fattori che non si osservano nè si controllano possono influenzare il valore che si registra, quindi pur replicando l'esperimento nelle stesse condizioni, si otterranno quasi certamente valori differenti.

In termini matematici questo significa che, si può assumere di avere una grandezza in esame che sia essa stessa una variabile aleatoria $X \in \mathcal{X}$[1] è un'ipotesi di modellazione che, pur non essendo dimostrabile, risulta estremamente vantaggiosa, poichè ci dà accesso agli strumenti della probabilità e della statistica. In questi termini, le osservazioni $x_1, \ldots, x_n$ sono realizzazioni di variabili aleatorie $X_1, \ldots, X_n$, indipendenti e identicamente distribuite come $\mathcal{X}$.

In questo contesto si affronta un problema di classificazione, in cui ogni osservazione comprende sia la feature x sia un'etichetta di classe y. Oltre alla variabile X, si introduce una seconda variabile aleatoria $Y \in \mathcal{Y}$. Si definiscono i dati raccolti come un campione $(x_1, y_1), \ldots, (x_n, y_n)$ composto da n realizzazioni indipendenti e identicamente distribuit della coppia (X, Y).

Il problema quindi è il seguente: a partire dai dati è necessario costruire una regola che, dato un nuovo valore x ne predice l'etichetta y. Di seguito si vede uno dei modi più semplici e interpretabili per risolvere questo problema chiamato albero di decisione (Decision Tree).

[1] Si suppone di raccogliere n misurazioni di una stessa grandezza. Si indica con $\mathcal{X}$ l'insieme dei valori possibili, e le osservazioni effettivamente raccolte con $x_1, \ldots, x_n$.

3.1 Decision Tree nel caso unidimensionale

Il Decision Tree è un modello che permette di fare previsioni attraverso suddivisioni binarie dello spazio delle osservazioni.

Ad ogni passo l'algoritmo seleziona una variabile e una soglia (*threshold*) di separazione, dividendo i dati in due sottogruppi in base alla soglia. Il processo viene ripetuto ricorsivamente per ciascun sottogruppo, generando una struttura ad albero in cui ogni nodo interno rappresenta una decisione binaria e ogni foglia restituisce una previsione.

Per introdurre in modo intuitivo questo meccanismo, si consideri il caso unidimensionale.

Si definisca come input $x = \text{SpeedST} \in \mathcal{X} \subseteq \mathbb{R}$ e come output $y = \text{HighDeg} \in \{0, 1\}$.

Si assuma $A_0 = \{\mathcal{X}\}$ come il nodo radice, ovvero tutto il dataset.

Si inizia con il dividere il nodo radice in:

$$A_1(s) = \{x \in A_0 : \text{SpeedST} \leq s\} \qquad A_2(s) = \{x \in A_0 : \text{SpeedST} > s\}$$

Per determinare quale sia la soglia ottimale, si introduce per ogni cella A il rischio empirico, che misura l'errore commesso dal modello: la soglia ottimale è quella che lo minimizza. Il rischio empirico è definito come la proporzione di osservazioni classificate erroneamente rispetto alla previsione costante c_A associata alla cella

$$\hat{R}_A = \frac{1}{n_A} \sum_{x_i \in A} \mathbb{1}_{y_i \neq c_A}$$

dove n_A è il numero di osservazioni nella cella A e c_A è la classe maggioritaria tra le osservazioni in A.

La soglia s viene scelta minimizzando la somma dei rischi empirici delle due celle risultanti dalla suddivisione:

$$s^* = \arg\min_s [\hat{R}_{A_1(s)} + \hat{R}_{A_2(s)}]$$

Il procedimento viene poi applicato ricorsivamente creando una struttura ad albero: ogni *nodo interno* corrisponde ad uno *split*, mentre ogni *foglia* rappresenta il punto d'arrivo, a cui è associata una previsione costante. Nell'ottica di illustrare il meccanismo appena descritto si realizza un esempio applicato alla Formula 1. Si consideri un campione di 18 osservazioni relative al Gran Premio del Bahrain 2022, mostrato nella Tabella 3.1:

Applicando la regola di minimizzazione definita nel paragrafo 3.1, si calcola $\hat{R}_{A_1(s)} + \hat{R}_{A_2(s)}$ per diverse soglie candidate. Ad esempio, per $s = 311$ la cella A_1 contiene una sola osservazione con HighDeg $= 1$; la classe maggioritaria è quindi $c_{A_1} = 1$ e, non essendoci osservazioni classificate erroneamente, $\hat{R}_{A_1} = 0$. La cella A_2 contiene le restanti 17 osservazioni, di cui 9 con HighDeg $= 1$ e 8 con HighDeg $= 0$: la classe maggioritaria è $c_{A_2} = 1$, e le 8 osservazioni con $y = 0$ vengono classificate erroneamente, dando $\hat{R}_{A_2} = \frac{8}{17} = 0.471$.

SpeedST	HighDeg
310.0	1
313.0	0
313.0	0
313.0	0
313.0	1
314.0	1
314.0	0
314.0	0
314.0	1
314.0	0
315.0	0
317.0	1
317.0	1
318.0	0
318.0	1
319.0	1
320.0	1
322.0	1

Tabella 3.1: Campione di 18 osservazioni, Gran Premio del Bahrain 2022.

s	$\hat{R}_{A_1(s)}$	$\hat{R}_{A_2(s)}$	$\hat{R}_{A_1(s)} + \hat{R}_{A_2(s)}$
311	0.000	0.471	0.471
313	0.400	0.385	0.785
314	0.400	0.250	0.650
316	0.364	0.143	0.507
317	0.462	0.200	0.662
318	**0.467**	**0.000**	**0.467**
319	0.500	0.000	0.500
321	0.471	0.000	0.471

Tabella 3.2: Somma dei rischi empirici per tutte le soglie candidate, Gran Premio del Bahrain 2022.

La soglia che minimizza la somma dei rischi empirici è $s^* = 318$ come mostrato in Tabella 3.2, di conseguenza si ottiene:

- $A_1(s^*)$: SpeedST ≤ 318, con 15 osservazioni (8 HighDeg = 0, 7 HighDeg = 1) $\rightarrow$ previsione $c_{A_1} = 0$
- $A_2(s^*)$: SpeedST > 318, con 3 osservazioni, tutte HighDeg = 1 $\rightarrow$ previsione $c_{A_2} = 1$

Si osservi che, avendo preso un campione ridotto a scopo illustrativo, la partizione non è bilanciata; su un campione più ampio ci si aspetta una soglia più stabile e una divisione meno estrema. Inoltre, bisogna considerare che questo è un caso a una sola variabile; nella realtà si opera su più *feature* contemporaneamente.

3.2 Estensione al caso multidimensionale

Il meccanismo descritto nel caso unidimensionale si generalizza al caso in cui le osservazioni siano descritte da p variabili anzichè da una sola. In questo caso ogni split non seleziona più soltanto una soglia, ma anche la variabile rispetto alla quale fare la suddivisione.

Si definisca come input $x = (x_1, \ldots, x_p) \in \mathcal{X} \subseteq \mathbb{R}^p$, dove ad esempio $p = 2$ con $x_1 = \text{SpeedST}$ e $x_2 = \text{SpeedI1}$, e come output $y = \text{HighDeg} \in \{0, 1\}$.

Come nel caso unidimensionale, si assume $A_0 = \{\mathcal{X}\}$ come nodo radice. Ogni cella A viene suddivisa scegliendo una variabile $j \in \{1, \ldots, p\}$ e una soglia s:

$$A_1(j, s) = \{x \in A : x_j \leq s\} \qquad A_2(j, s) = \{x \in A : x_j > s\}$$

La scelta dello *split* si basa sulla minimizzazione del rischio empirico.

$$(j^*, s^*) = \arg\min_{j,s} [\hat{R}_{A_1(j,s)} + \hat{R}_{A_2(j,s)}]$$

In pratica, per ogni variabile x_j si considerano tutte le soglie candidate, si calcola la somma dei rischi empirici risultanti, e si seleziona la combinazione che minimizza tale somma su tutte le variabili disponibili.

Per un semplice caso di studio si può considerare lo stesso campione di 18 osservazioni del Gran Premio del Bahrain 2022 utilizzato nella sezione precedente, aggiungendo ora la variabile $x_2 = \text{SpeedI1}$.

SpeedST	SpeedI1	HighDeg
310.0	238.0	1
313.0	239.0	0
313.0	240.0	0
313.0	239.0	0
313.0	237.0	1
314.0	240.0	1
314.0	240.0	0
314.0	239.0	0
314.0	240.0	1
314.0	240.0	0
315.0	240.0	0
317.0	241.0	1
317.0	241.0	1
318.0	235.0	0
318.0	235.0	1
319.0	240.0	1
320.0	240.0	1
322.0	239.0	1

Tabella 3.3: Campione di 18 osservazioni, Gran Premio del Bahrain 2022.

Come nel caso unidimensionale, per ogni variabile si considerano tutte le soglie candidate e si calcola la somma dei rischi empirici risultante; la differenza è che ora il confronto lo si applica anche tra le variabili e si sceglie la combinazione con la somma più bassa in assoluto.

Per SpeedST, la soglia migliore rimane $s = 318$, con somma 0.467 (come visto in Tabella 3.2). Testando alcune soglie candidate anche su SpeedI1, si prende per esempio $s = 240$; la cella A_1 ha 8 osservazioni con HighDeg = 1 e 8 osservazioni con HighDeg = 0. Per convenzione si assume $c_{A_1} = 1$, da cui $\hat{R}_{A_1} = \frac{8}{16} = 0.500$. La cella A_2 contiene 2 osservazioni con HighDeg = 1 e quindi $\hat{R}_{A_2} = 0$, perciò la somma è 0.500. La combinazione migliore per il primo split è $(j^*, s^*) = (\text{SpeedST}, 318)$.

Il procedimento si ripete poi ricorsivamente sulla cella A_1 risultante. In questa fase, tuttavia, la logica si capovolge: continuando a suddividere su SpeedST, la soglia migliore $s = 316$ produce una somma di 0.506; suddividendo invece su SpeedI1 con soglia $s = 240$, la somma è 0.385. In questo caso la soglia migliore è $(j^*, s^*) = (\text{SpeedI1}, 240)$.

La Figura 3.1 fornisce una rappresentazione spaziale del meccanismo, mostrando il rischio empirico al variare congiunto delle due soglie (s_1 e s_2) per la coppia di variabili (SpeedST e SpeedI1). Data la ridotta dimensione del campione, alcune regioni della griglia (esempio $s \leq 311.5$) presentano pochissime osservazioni per cella, rendendo i valori di rischio meno stabili e informativi. Questo limite non incide sulla scelta ottimale dello *split*, evidenziato in figura, che è coerente con i risultati ottenuti analiticamente.

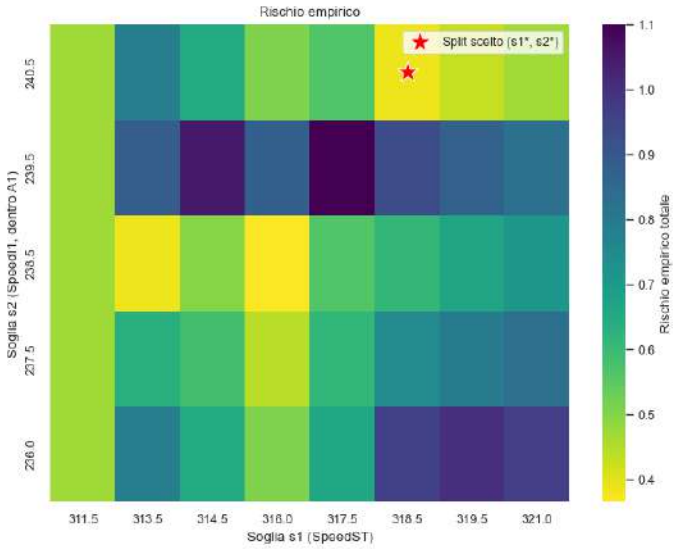


Figura 3.1: Rischio empirico al variare delle soglie s_1 (SpeedST) e s_2 (SpeedI1)

Come mostra l'esempio, il modello è capace di adattare lo *split* allo spazio dei dati. Questa flessibilità aumenta all'aumentare di p. Tuttavia questa elevata flessibilità comporta un rischio: l'albero può adattarsi eccessivamente alle particolarità del dataset di addestramento (*overfitting*), creando delle suddivisioni poco generalizzanti.

3.3 Limiti del Decision Tree singolo

La grande capacità di adattamento degli alberi decisionali ai dati di addestramento ne garantisce la minimizzazione del rischio empirico, ma ne rappresenta anche il maggior punto di debolezza. Questi modelli sono infatti estremamente sensibili al training set: piccole variazioni nei dati possono alterare la struttura dell'albero (si veda la Sezione 3.4).

Per comprendere la natura di questa instabilità, è utile ricorrere alla scomposizione dell'errore di generalizzazione nelle sue componenti fondamentali: *bias* e *varianza*. Il bias indica la deviazione sistematica delle stime del modello dal valore vero; la varianza quantifica invece quanto le previsioni oscillino al cambiare del dataset di addestramento. In termini formali, l'errore atteso di generalizzazione risulta essere:

$$\text{Errore atteso} = \text{Bias}^2 + \text{Varianza} + \text{Rumore irriducibile}$$

Un albero decisionale sviluppato in profondità, privo di vincoli sulla dimensione delle foglie, tende ad avere un bias basso: la continua suddivisione dello spazio delle osservazioni consente all'albero di adattarsi quasi perfettamente ai dati di addestramento, riducendo l'errore empirico fino ad annullarlo del tutto. Questa flessibilità, però, determina un'elevata varianza: la struttura dell'albero risulta estremamente sensibile alla specifica composizione del training set. Lievi alterazioni del dataset - come l'aggiunta, la rimozione o il ricampionamento di poche osservazioni - possono modificare in modo sostanziale i primi *split* e le variabili selezionate (come verrà illustrato successivamente). Questa elevata varianza compromette la capacità di generalizzazione del modello, riducendone l'efficacia su nuove osservazioni.

Per illustrare questo fenomeno, si allena un albero decisionale utilizzando come predittori le variabili SpeedST e SpeedI1, con l'obiettivo di predire HighDeg, facendo variare la profondità massima dell'albero da 1 a 9 e valutando le prestazioni tramite *k-fold cross-validation*[2]. La Figura 3.2 mostra un tipico comportamento di overfitting: l'accuratezza sul training set cresce con la profondità, da $0,565$ a profondità 1 a $0,734$ a profondità 9, mentre quella sul test set raggiunge un massimo di $0,630$ a profondità 7 e poi decresce, scendendo a $0,590$ a profondità 9. Questo scostamento tra le curve indica che superata la profondità ottimale, l'albero tende a memorizzare rumore o dettagli specifici del training set. Ciò limita la sua capacità di generalizzare e peggiora le prestazione sui dati non visti.

[2]La k-fold cross-validation suddivide i dati in k parti uguali. Il processo si ripete k volte: a ogni iterazione, $k-1$ parti servono ad addestrare il modello, mentre la parte esclusa viene usata come test set per valutarne le prestazioni. L'accuratezza finale è data dalla media delle k valutazioni. Questo approccio assicura che ogni fold rispetti la distribuzione originale delle classi.

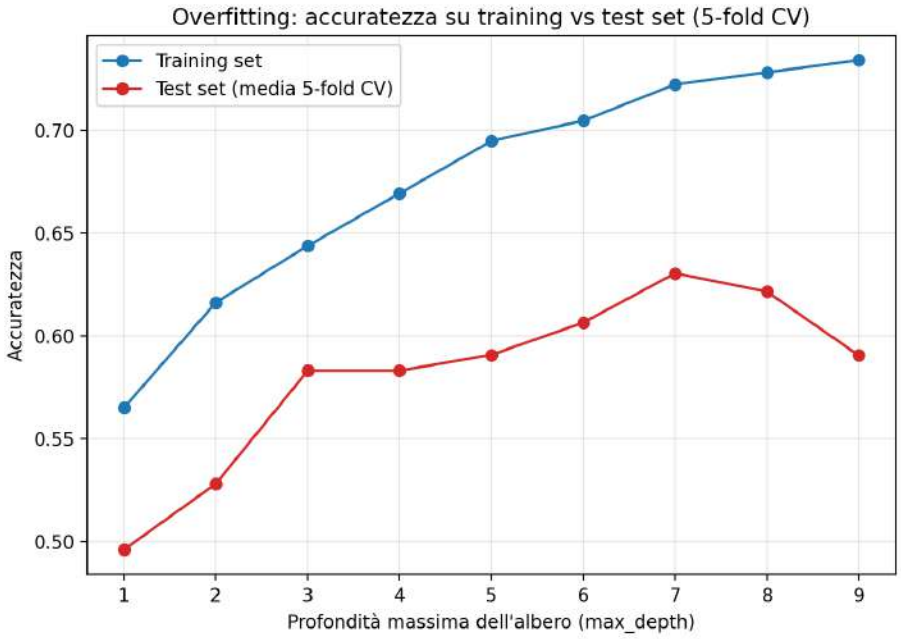


Figura 3.2: Accuratezza su training e test set al variare della profondità massima dell'albero, Gran Premio del Bahrain.

Un singolo albero decisionale, per quanto flessibile, non è in grado di distinguere le reali regolarità dei dati dal rumore campionario. Una strategia efficace per ovviare a questo problema è utilizzare il *Bagging*.

3.4 Bagging (Bootstrap Aggregating)

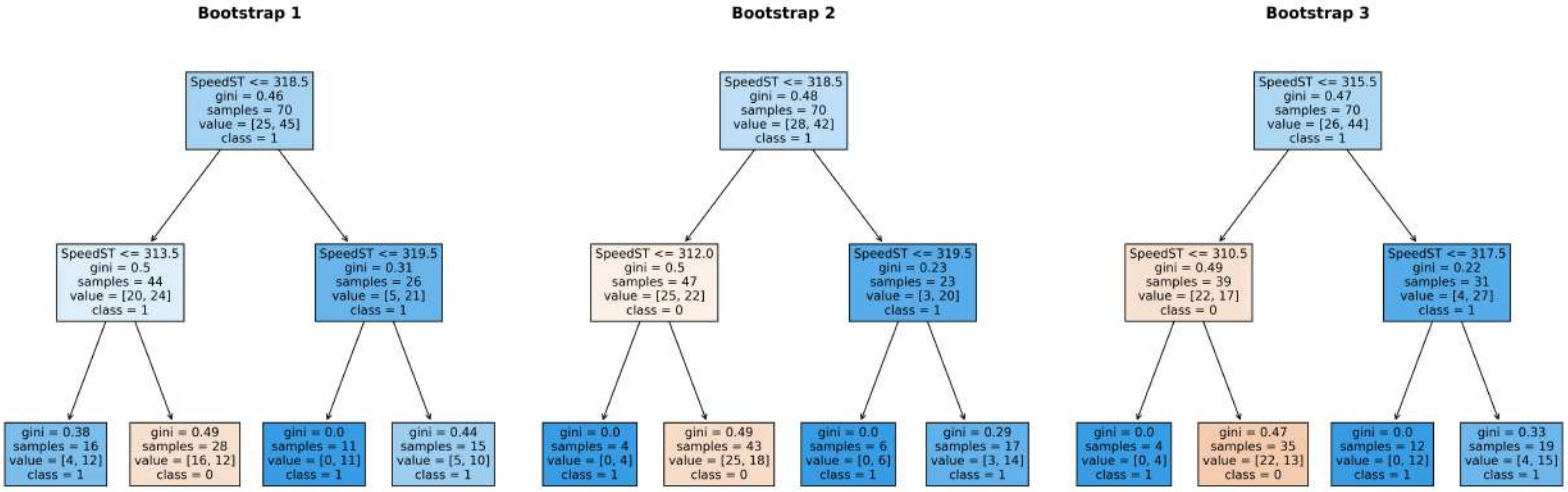
Il *bagging* è un metodo che affronta l'instabilità appena descritta allenando più alberi sugli stessi dati, ma visti in versioni diverse, e combinandone poi le previsioni. Per ottenere queste versioni di training set diverse si utilizza il *bootstrap*: a partire dal training set originale di N osservazioni, si costruiscono B nuovi campioni $Z^{*1}, \ldots, Z^{*B}$, ciascuno ottenuto campionando N osservazioni in modo casuale con reinserimento. Questo significa che una stessa osservazione può comparire più volte nello stesso campione, mentre altre potrebbero non comparire affatto.

A partire dai B campioni bootstrap $Z^{*1}, \ldots, Z^{*B}$, si addestra un albero decisionale su ciascun dataset (secondo la procedura delle Sezioni 3.1-3.2). Si generano così B modelli $T_1, \ldots, T_B$: nonostante si utilizzi lo stesso algoritmo, gli alberi danno risultati diversi perchè sono istruiti su diverse combinazioni di dati.

Per illustrare concretamente l'instabilità degli *alberi bagged*, si applica la procedura di costruzione dell'albero (limitata a profondità 2, per leggibilità) a $B = 6$ campioni bootstrap generati dalle

70 osservazioni del Gran Premio del Bahrain 2022, utilizzando le variabili SpeedST e SpeedI1 già introdotte in Sezione 3.2[3].

La Figura 3.3 mostra i sei alberi risultanti. Si osserva che la variabile scelta per il primo split non è sempre la stessa: in quattro casi su sei il primo split avviene su SpeedST (con soglie comprese tra 315.5 e 318.5) mentre nei restanti due casi il primo split avviene su SpeedI1 (236.0). Questo cambio di struttura dell'albero, non solo nelle soglie, ma nella scelta stessa delle variabili di split, è precisamente il tipo di instabilità che il bagging si propone di attenuare attraverso l'aggregazione.



[3]Gli alberi di questo esempio sono costruiti con la libreria python `scikit-learn`, che utilizza il criterio di *Gini impurity* anziché il rischio empirico adottato nel resto del capitolo; la scelta della variabile di *split*, tuttavia, non risulta sostanzialmente influenzata da questa differenza.

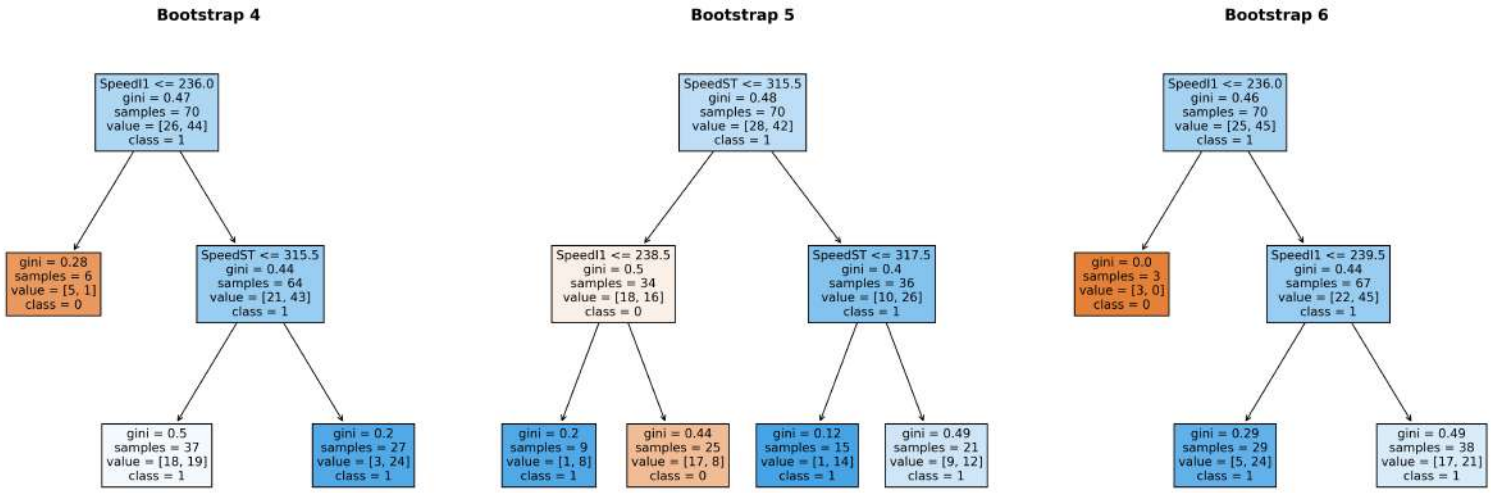


Figura 3.3: Alberi di profondità 2 allenati su sei campioni bootstrap, Gran Premio del Bahrain 2022 (SpeedST, SpeedI1).

Una volta ottenuti i B alberi $T_1, \ldots, T_B$, il bagging combina le previsioni in un'unica stima. Nel caso della regressione, la combinazione è una media:

$$\hat{f}_{bag}(x) = \frac{1}{B} \sum_{b=1}^{B} T_b(x)$$

Nel caso della classificazione ogni albero T_b assegna all'osservazione x un'etichetta di classe $\hat{G}_b(x) \in \{0, 1\}$. La classificazione finale del bagging si ottiene per voto di maggioranza tra i B alberi addestrati:

$$\hat{G}_{bag}(x) = \arg \max_{k \in \{0,1\}} \sum_{b=1}^{B} \mathbb{1}_{\{\hat{G}_b(x)=k\}}$$

Per comprendere il motivo per cui l'aggregazione attenui l'errore di classificazione è utile analizzare la logica dietro al voto di maggioranza. La teoria del bagging si basa su un principio noto come Teorema della giuria di Condorcet[4]:

Teorema 1 (Giuria di Condorcet)**.** *Siano $T_1, \ldots, T_B$ classificatori indipendenti, ciascuno con probabilità $p > 0.5$ di produrre la previsione corretta. Allora la probabilità che il voto di maggioranza tra i B classificatori sia corretto tende a 1 al crescere di B.*

In altri termini: se ogni albero possiede un tasso di errore inferiore al 50% e le decisioni dei singoli alberi sono mutualmente indipendenti, la probabilità di un'assegnazione corretta tramite il voto di maggioranza tende asintoticamente a 1 al crescere del numero di alberi B.

[4]Il principio è riconducibile al teorema della giuria di Condorcet (1785); la sua applicazione al contesto del bagging è discussa in [7, Cap. 8.7], con riferimento a Dietterich (2000a).

Nella pratica, la condizione di totale indipendenza non è mai soddisfatta. Derivando dal medesimo dataset di partenza (seppur ricampionando), gli alberi conservano una correlazione residua. Nonostante questo, l'aggregazione riesce a smorzare gli errori individuali.

Per misurare con esattezza questo effetto, si valuta la varianza della stima aggregata:

$$\hat{f}_{bag}(x) = \frac{1}{B}\sum_{b=1}^{B} T_b(x)$$

Si applica la definizione di varianza:

$$\mathrm{Var}(\hat{f}_{bag}(x)) = \mathrm{Var}(\frac{1}{B}\sum_{b=1}^{B} T_b(x))$$

Ricordando che $\mathrm{Var}(cX) = c^2\mathrm{Var}(X)$ e si ottiene:

$$\mathrm{Var}(\hat{f}_{bag}(x)) = \frac{1}{B^2}\mathrm{Var}(\sum_{b=1}^{B} T_b(x))$$

Se gli alberi fossero indipendenti, la varianza della somma sarebbe semplicemente la somma delle varianze. Ma, come discusso in precedenza, gli alberi bagged sono correlati, perciò la varianza di una somma di variabili correlate include la correlazione tra ogni coppia:

$$\mathrm{Var}(\sum_{b=1}^{B} T_b(x)) = \sum_{b=1}^{B} \mathrm{Var}(T_b(x)) + \sum_{b\neq b'} \mathrm{Cov}(T_b(x), T_{b'}(x))$$

La correlazione tra due alberi diversi indica quanto due alberi tendono a fare lo stesso errore.

Si assume che ogni albero abbia la stessa varianza σ^2 e che ogni coppia di alberi abbia la stessa correlazione ρ, si ottiene:

$$\mathrm{Var}\left(\sum_{b=1}^{B} T_b(x)\right) = B\sigma^2 + B(B-1)\rho\sigma^2$$

dove B è il numero di termini di varianza (uno per albero), e $B(B-1)$ definisce il numero di possibili coppie distinte (b, b') con $b \neq b'$. Dividendo per B^2 e semplificando:

$$\mathrm{Var}(\hat{f}_{bag}(x)) = \frac{B\sigma^2 + B(B-1)\rho\sigma^2}{B^2} = \frac{\sigma^2}{B} + \frac{B-1}{B}\rho\sigma^2 = \rho\sigma^2 + \frac{1-\rho}{B}\sigma^2$$

Il risultato mostra due contributi distinti: il termine $\frac{1-\rho}{B}\sigma^2$ diminuisce all'aumentare di B, come nel caso di alberi indipendenti; il termine $\rho\sigma^2$, invece, resta costante e rappresenta un limite inferiore alla varianza che non può essere eliminato aumentando il numero di alberi. L'obiettivo del Random Forest è proprio quello di ridurre la correlazione ρ.

Oltre alla riduzione di varianza, il meccanismo del bootstrap offre un ulteriore vantaggio pratico: consente di stimare l'errore del modello senza bisogno di un test set separato. Poichè ogni campione

bootstrap Z^{*b} non contiene tutte le N osservazioni originali, i dati esclusi risultano out-of-bag (OOB) per il singolo albero T_b, che non li ha mai utilizzati durante l'addestramento. Per ciascuna osservazione del training set, è quindi possibile calcolare una previsione aggregando esclusivamente gli alberi per i quali tale osservazione risulta OOB. Il confronto con l'etichetta reale restituisce così una valutazione affidabile dell'errore di generalizzazione [1, Sez. 3].

Per mostrare il meccanismo OOB, si considera un'osservazione del campione facendo riferimento ai sei alberi di bootstrap illustrati nella Figura 3.3. Tra questi, tre risultano out-of-bag per il punto in esame (SpeedST = 322.0, SpeedI1 = 239.0, HighDeg = 1): gli alberi associati ai campioni 1,4 e 5. Aggregando mediante voto di maggioranza le sole stime prodotte da questi tre alberi, si ottiene una classificazione unanime per la classe 1 (Tabella 3.4), coerente con il dato osservato. Applicando questo calcolo a tutte le osservazioni e confrontando le stime OOB con i valori reali, si ottiene una valutazione dell'errore di generalizzazione.

Albero bootstrap	Previsione
1	1
4	1
5	1
Voto di maggioranza	**1**

Tabella 3.4: Previsioni OOB per l'osservazione considerata (SpeedST= 322.0, SpeedI1= 239.0), etichetta vera HighDeg= 1.

3.5 Random Forest

Come si è visto nella Sezione 3.4, il bagging riduce la varianza della previsione aggregata, ma la correlazione residua ρ tra gli alberi impone un limite inferiore. Per superare questo vincolo, Breiman (2001) ha introdotto le Random Forest, un approccio che incrementa la casualità nella fase di strutturazione di ciascun albero con l'obiettivo specifico di diminuire ρ. A differenza del bagging che ad ogni nodo considera tutte le p variabili disponibili, la Random Forest vincola la ricerca del punto di divisione ottimale (j^*, s^*) (Sezione 3.2) a un sottoinsieme ridotto di $m \leq p$ variabili, estratto casualmente prima di ogni nodo. Il processo di campionamento delle m variabili si ripete in maniera autonoma per ogni nodo e per ogni albero dell'insieme[5].

Per comprendere l'efficacia delle Random Forest, è utile analizzare il quadro teorico sviluppato da Breiman[1], basato su due concetti: il margine e la forza (strength) dei classificatori.

Sia $h(x, \Theta)$ un generico albero della foresta, dove Θ è una variabile aleatoria che contiene l'intera componente di casualità utilizzata per la costruzione. I singoli alberi della foresta, $T_1, \ldots, T_B$, corrispondono a realizzazioni $h(x, \Theta_1), \ldots, h(x, \Theta_b)$ con Θ_b indipendenti e identicamente distribuiti.

Nel caso di classificazione binaria $y \in \{0, 1\}$, il margine $\mathrm{mr}(x, y)$ misura il vantaggio con cui la maggioranza degli alberi individua la classe corretta:

$$\mathrm{mr}(x, y) = 2P_\Theta(h(x, \Theta) = y) - 1$$

[5]In contesti di classificazione si imposta comunemente $m = \lfloor \sqrt{p} \rfloor$ [7, Cap. 15]

dove $P_\Theta(h(x,\Theta)) = y$ indica la probabilità (rispetto alla distribuzione di Θ) che un albero generico classifichi correttamente l'osservazione. In pratica: per ogni albero b, si guarda se la sua previsione $T_b(x)$ coincide con l'etichetta vera y - se sì, conta 1, altrimenti 0. Si sommano questi 0 e 1 su tutti i B alberi, e si divide per B.

$$P_\Theta(h(x,\Theta) = y) \approx \frac{1}{B} \sum_{b=1}^{B} \mathbb{1}_{\{T_b(x)=y\}}$$

Il margine misura, quindi, quanto la foresta sia convinta della propria risposta per un data osservazione. Se $\mathrm{mr}(x,y)$ è vicino a 1, vuol dire che quasi tutti gli alberi sono d'accordo sulla classe giusta, un valore vicino a 0 segnala una decisione incerta, mentre un valore negativo identifica un errore di classificazione.

La forza (s) della foresta è definita come il margine medio sull'intero spazio delle osservazioni (X,Y):

$$s = \mathbb{E}_{X,Y}[\mathrm{mr}(X,Y)]$$

Una condizione fondamentale per l'efficacia del modello è che la forza sia positiva ($s > 0$). Se i singoli alberi fornissero un'accuratezza media inferiore a quella del caso (50%), la regola di maggioranza risulterebbe inefficace.

Breiman dimostra che l'errore di generalizzazione della foresta,

$$PE^* = P_{X,Y}(\mathrm{mr}(X,Y) < 0)$$

può essere legato a s e alla correlazione ρ tra gli alberi tramite un ragionamento analogo a quello della sezione 3.4. In primo luogo si applica la diseguaglianza di Chebyshev al margine, ottenendo un primo limite in funzione della sua varianza; successivamente, tale varianza si scompone in un termine dipendente dalla correlazione media ρ tra le coppie di alberi. Rispetto alla derivazione del bagging, la differenza risiede nel fatto che la correlazione non viene calcolata sulle previsioni dirette degli alberi, ma sul loro margine singolo, che risulta limitato nell'intervallo $[-1,1]$.

Il risultato finale è il seguente:

Teorema 2 (Bound sull'errore di generalizzazione, Breiman 2001)**.** *Sia PE^* l'errore di generalizzazione della foresta, s la sua forza e ρ la correlazione media tra le coppie di alberi. Allora:*

$$PE^* \leq \frac{\rho \cdot (1 - s^2)}{s^2}$$

Questo risultato mostra come l'errore di una Random Forest dipenda esclusivamente dalla forza s e dalla correlazione ρ tra gli alberi. Il rapporto ρ/s^2 misura l'efficienza complessiva del modello: minore è il suo valore, più accurata sarà la foresta. Per ridurre il rapporto occorre aumentare la forza s o diminuire la correlazione ρ. In pratica, esiste un compromesso controllato dal parametro m (il numero di variabili selezionate casualmente a ogni nodo). Riducendo m, gli alberi considerano sottoinsiemi di variabili differenti, il che ne aumenta la diversità riducendo la correlazione ρ. Tuttavia, un valore di m troppo piccolo, rischia di escludere le variabili maggiormente predittive nella scelta dello split, compromettendo la precisione dei singoli alberi e riducendo la forza s.

Tutto questo conferma quanto già visto nella sezione 3.4: là il termine $\rho\sigma^2$ poneva un limite inferiore alla varianza del bagging; qui la stessa ρ limita superiormente l'errore di classificazione. Varianza e margine sono cose diverse che portano alla stessa conclusione: per far funzionare la Random Forest bisogna ridurre la correlazione ρ tra gli alberi, senza però sacrificare l'accuratezza.

3.6 Feature importance

Diversamente da un singolo albero di decisione, una foresta composta da centinaia di elementi risulta difficile da interpretare: non è più possibile individuare a vista quali variabili incidano sulla previsione e in che modo. Come osserva lo stesso Breiman, una foresta diventa una scatola chiusa, per ovviare a questo limite, l'autore ha introdotto un indice di importanza delle variabili in grado di quantificare il contributo di ciascuna feature nel processo di stima.

Il metodo si basa sull'utilizzo delle osservazioni out-of-bag (OOB), già citate nella Sezione 3.4. In concreto, per ogni albero e per ciascuna variabile, si permutano in modo casuale i soli valori OOB della variabile considerata, mentre gli altri dati rimangono invariati. Si calcola, quindi, l'aumento dell'errore di classificazione generato da questa alterazione. Se una variabile è determinante per il modello, comprometterne la capacità informativa provoca un peggioramento delle stime; al contrario, se il suo peso è marginale, la qualità della classificazione rimane inalterata. La media di questi incrementi d'errore calcolata su tutti gli alberi definisce l'indice globale di importanza[7, Cap. 15.3.2].

Un aspetto critico di questo meccanismo riguarda la presenza di variabili fortemente correlate. Quando due variabili contengono la stessa informazione predittiva, permutare l'una o l'altra separatamente produce un aumento dell'errore simile, poiché il modello tende ad alternarle nei nodi di decisione. Come notato da Breiman nell'analisi del dataset diabetes[1], l'influenza di una variabile tende a ridursi quando una caratteristica equivalente fa già parte del modello.

Il percorso svolto ha mostrato la transizione dai singoli alberi decisionali alla Random Forest, evidenziando il passaggio da modelli instabili ad architetture capaci di controllare la varianza e l'errore atteso. Nei capitoli successivi questi strumenti saranno messi alla prova su un problema concreto, e, come si vedrà, non sempre il segnale nei dati reali si comporta come i modelli teorici lascerebbero sperare.

Capitolo 4

Dati e metodologia

Dopo aver analizzato il contesto ingegneristico della Formula 1 e i fondamenti teorici del Random Forest, questo capitolo descrive la metodologia adottata per l'analisi applicativa sui dati. L'obiettivo principale è verificare se le velocità registrate dalle vetture, legate al relativo assetto aerodinamico, consentano di prevedere un degrado degli pneumatici superiore o inferiore rispetto alla mediana del circuito. Il problema viene strutturato come una classificazione binaria e sviluppato attraverso modelli lineari e non lineari.

4.1 Libreria FastF1 e creazione del dataset

I dati sono stati raccolti dalla libreria Python *open source* **FastF1**, compatibile con la libreria *pandas* utile per l'analisi e la manipolazione dei dati. FastF1 offre accesso diretto ai dati ufficiali della Formula 1, tra cui tempi sul giro, mescola ed età delle gomme, apertura dell'acceleratore e condizioni meteorologiche.

Il dataset comprende le stagioni dal 2022 al 2025, anni che seguono lo stesso regolamento e ci si concentra solo sui Gran Premi presenti in tutti gli anni.

Per stimare il carico aerodinamico della vettura di ciascun pilota, si sono presi in esame i dati del loro miglior giro in qualifica, concentrandosi sulle velocità allo *speed trap* e negli intermedi (*SpeedST, SpeedI1, SpeedI2*). I valori di velocità sono condizionati dal carico aerodinamico: a parità di potenza, un carico elevato aumenta il *drag* e limita la velocità massima. Allo stesso tempo, la spinta aerodinamica aumenta il carico verticale e lo stress sulle mescole. Un assetto con meno carico riduce gli sforzi meccanici limitando l'usura degli pneumatici [9]. Le velocità assolute dipendono dal circuito e dalle condizioni della pista, quindi non sono confrontabili tra gare diverse. Per questo motivo si ricorre a una misura relativa, calcolata sottraendo dalla velocità di ciascun pilota la mediana di tutti i piloti nella stessa gara. Un valore positivo evidenzia una monoposto più veloce della mediana, mentre un valore negativo indica una vettura più lenta. Si definiscono così le *feature* del dataset: *SpeedST_rel, SpeedI1_rel, SpeedI2_rel*.

Per analizzare il passo gara sono stati selezionati solo i giri più indicativi, scartando le soste ai box, i tempi oltre il 107% del miglior giro (in quanto non rappresentativi del ritmo reale del pilota) e quelli corsi in regime di safety car o virtual safety car.

Per misurare il degrado delle gomme, si usano i tempi sul giro, corretti in base al carburante consumato (si sottrae 0.03 secondi per ogni chilo di carburante ancora a bordo, si assume un carico iniziale di 110 kg [16, 14]). In questo modo i tempi sono confrontabili tra loro come se il peso fosse sempre lo stesso. Successivamente, per ogni *stint*, cioè per ogni sequenza di giri consecutivi con la stessa mescola, i tempi vengono inseriti in un grafico in funzione dell'età della gomma per tracciare una retta. Il coefficiente angolare ottenuto misura il degrado, indicando quanti secondi al giro si perdono in media per ogni giro di utilizzo dei pneumatici.

Ogni riga del dataset finale corrisponde a uno *stint* di un pilota in gara.

4.2 Costruzione della variabile target

Per costruzione il degrado di uno stint è un numero continuo, che indica di quanto il pilota rallenta in media ad ogni giro a causa dell'usura della gomma. Ad esempio, un valore di 0.05 significa che ogni giro è più lento del precedente di 0.05 secondi.

Volendo passare a una classificazione binaria, si separa il degrado **alto** da quello **basso** rispetto ad un valore di riferimento.

L'usura dipende dal circuito e dalla mescola: alcuni tracciati consumano le gomme più di altri e ciascuna mescola tende a deteriorarsi con ritmi differenti. Per questo motivo, il valore di riferimento non è unico, ma viene definito per ogni coppia (circuito, mescola), il che consente un confronto coerente tra stint in condizioni simili. Come soglia si usa la mediana del degrado, e la classificazione è data dalla seguente equazione:

$$y_i = \begin{cases} 1 \text{ (alto)} & \text{se } d_i > d_{c,m}, \\ 0 \text{ (basso)} & \text{altrimenti,} \end{cases} \tag{4.1}$$

dove d_i è il degrado dell'i-esimo stint e $d_{c,m}$ è la mediana per il circuito c e la mescola m.

Su quali dati venga calcolata la mediana è descritto nella sezione successiva.

4.3 Divisione training set e test set

Lo scopo dello studio è quello di prevedere il degrado in una nuova stagione basandosi sugli anni precedenti.

Il dataset è diviso in *training set* e *test set*. Il training set, utilizzato per addestrare i modelli, comprende le stagioni dal 2022 al 2024, mentre il test set, usato per valutare le prestazioni dei modelli su dati mai visti, contiene la stagione 2025. Lo *split* è fatto per anno e non in modo casuale, perchè gli stint della stessa gara sono molto simili tra loro e una divisione casuale renderebbe il test troppo facile.

Anche il target rispetta questa divisione. Le mediane sono calcolate solo sul training set e successivamente applicate al test set, facendo in modo che nessuna informazione sul 2025 influenzi le classi (evitando *data leakage*[1]).

Vengono esclusi dal test set gli stint con combinazioni non presenti nel training set per mancanza di una mediana di confronto.

4.4 Analisi statistica preliminare

Prima di addestrare i modelli è importante analizzare i dati presenti nel dataset.

La Tabella 4.1 riporta la distribuzione delle classi di degrado. Nel training set le due classi sono bilanciate, perchè la soglia è definita tramite la mediana. Nel test set la classe di degrado basso è leggermente più frequente, ma la differenza tra le due è contenuta e non crea problemi.

	Degrado basso	Degrado alto	Totale
Training set	981 (50,6%)	957 (49,4%)	1938
Test set	336 (55,0%)	275 (45,0%)	611

Tabella 4.1: Distribuzione della variabile target *HighDeg*.

Per quanto riguarda le velocità relative, la Tabella 4.2 riporta le principali statistiche descrittive (media, deviazione standard, minimo e massimo).

Variabile	Media	Deviazione standard	Minimo	Massimo
SpeedST_rel	−0.21	4.52	−30.00	17.00
SpeedI1_rel	−0.23	5.25	−47.50	19.50
SpeedI2_rel	−0.43	6.97	−186.00	13.00

Tabella 4.2: Statistiche descrittive delle velocità relative in km/h nel training set.

Come atteso, le medie sono vicine allo zero, perchè le velocità sono centrate sulla mediana di ciascuna gara. La deviazione standard evidenzia come le vetture si discostino dalla mediana di pochi chilometri orari. La forte asimmetria tra i valori minimi e i massimi segnala una coda di distribuzione orientata verso i valori più bassi. Il valore minimo di SpeedI2_rel è un caso estremo e riguarda soli due record consecutivi, appartenenti ad uno stesso pilota nel Gran Premio dell'Arabia Saudita 2023, il loro effetto sul modello è trascurabile.

La Figura 4.1 mette a confronto le distribuzioni delle tre velocità relative tra stint a basso e alto degrado. I risultati mostrano che le mediane di SpeedST e SpeedI1 coincidono e le rispettive dispersioni sono quasi identiche. Mentre SpeedI2 evidenzia una dispersione leggermente minore nel gruppo di alto degrado. In sintesi, le distribuzioni si sovrappongono in gran parte e nessun parametro di velocità, da solo, riesce a separare i due livelli di degrado.

[1]Nella Data Science avviene quando i dati di addestramento contengono informazioni sul futuro, rendendo i risultati migliori della realtà.

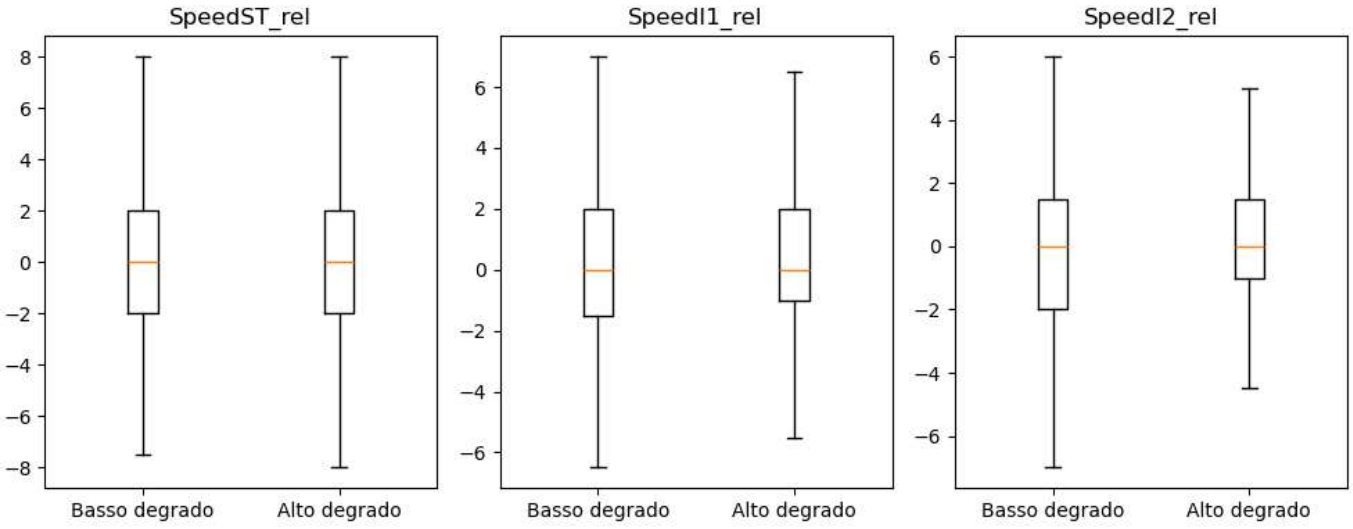


Figura 4.1: Distribuzione delle velocità relative (km/h) per classe di degrado nel training set.

4.5 Modelli a confronto e validazione

La classificazione si basa sul confronto tra quattro modelli: uno lineare, Regressione Logistica, e tre non lineari, k-Nearest Neighbors, Albero Decisionale e Random Forest.

Ogni modello è inserito in una **pipeline**, ovvero una sequenza automatica di passaggi che prepara e organizza i dati, in modo che ogni operazione sia eseguita sempre nello stesso modo. Inizia sostituendo eventuali valori mancanti con la mediana. Dopo di che porta le feature sulla stessa scala, in modo che nessuna variabile influenzi il modello più delle altre solo perchè assume valori distribuiti su un intervallo più ampio. Infine, i dati vengono forniti al modello classificatore.

Oltre ai passaggi previsti dalla pipeline, i classificatori necessitano di **iperparametri**, che non vengono appresi dai dati, ma vanno scelti prima dell'addestramento. Ad esempio, nell'Albero Decisionale un iperparametro corrisponde alla profondità massima, mentre nel kNN è il numero di vicini. Questi parametri servono a regolare la complessità del modello, cioè quanto è flessibile nell'imparare dai dati. Se il modello è troppo semplice non coglie le differenze tra gli stint, mentre se è troppo complesso si adatta ai dati di addestramento e sbaglia su quelli nuovi. Per scegliere gli iperparametri migliori si usa una *grid search*. In pratica, si provano diverse combinazioni di valori e si tiene quella con i risultati migliori. La qualità di ogni configurazione si misura con la *balanced accuracy*, un indicatore che pesa allo stesso modo la capacità di riconoscere i casi ad alto e basso degrado, evitando che una categoria prevalga sull'altra. In questo modo, un modello che predice sempre la stessa classe ottiene un punteggio di 0.5, un risultato pari alla sorte che definisce la soglia minima da superare.

La verifica di ciascuna combinazione avviene tramite la *cross-validation*[2], applicata solo al training set. Per l'analisi si applica una divisione per stagione (*leave-one-group-out*). Il modello viene

[2]vedi capitolo 3

addestrato su due stagioni e validato sulla terza, per un totale di tre volte. La balanced accuracy di una combinazione è la media dei tre risultati.

Si sceglie il modello con la migliore balanced accuracy media, insieme ai suoi iperparametri ottimali, e solo alla fine lo si valuta sul test set.

Capitolo 5

Risultati

Le analisi sono state svolte in Python: *pandas* per la gestione dei dati e *scikit-learn* per l'addestramento e la valutazione dei modelli.

5.1 Performance dei modelli

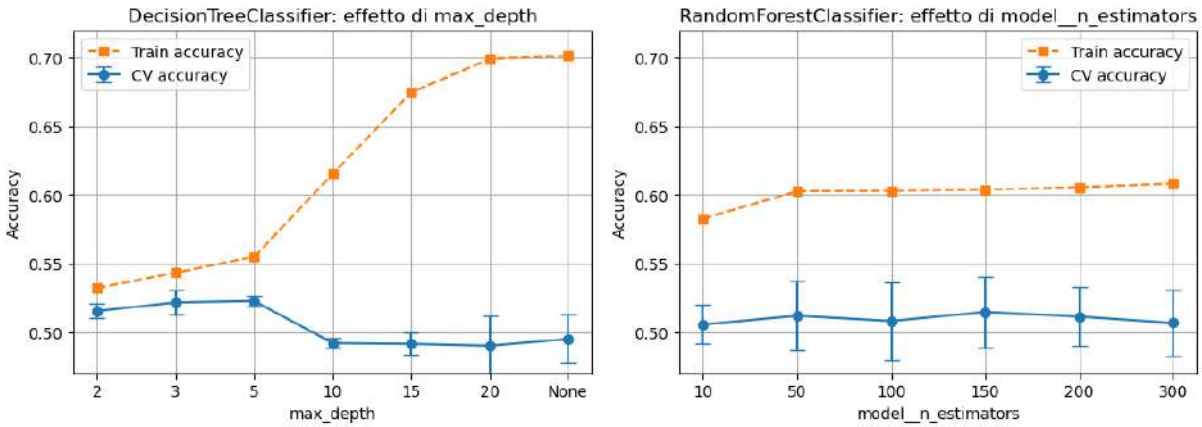
Le prestazioni in *cross-validation* dei modelli ottenute sui dati di addestramento (stagioni 2022-2024) sono state confrontate con una semplice regola (*baseline*). Come modello di riferimento (*Dummy*), è stato scelto un classificatore che predice sempre la classe più frequente. Per costruzione, la sua balanced accuracy è pari a 0.5, perchè indovina sempre una classe, ma sbaglia completamente la seconda. I risultati sono riportati in Tabella5.1:

Modello	Iperparametri scelti	Balanced accuracy (CV)
Dummy (baseline)	—	0.500
Regressione Logistica	$C = 0.01$	0.512
kNN	$k = 30$	0.507
Albero Decisionale	**Profondità 3, foglia min. 5**	**0.522**
Random Forest	150 alberi, prof. 5, foglia min. 5	0.515

Tabella 5.1: Balanced accuracy in cross-validation sul training (2022-2024).

Nessun modello mostra un miglioramento netto rispetto alla baseline. I valori restano tra 0.507 e 0.522, superano la soglia del caso al massimo due punti e anche le differenze tra i diversi algoritmi sono ancora più contenute. Nello specifico, la Random Forest non riesce a superare il Decision Tree (0.515 contro 0.522), un risultato coerente con quanto illustrato nel Capitolo 3. Se da un lato la foresta consente di ridurre la varianza dei singoli alberi, dall'altro l'errore di generalizzazione resta vincolato alla forza s (Teorema 2). Dato che i singoli alberi mostrano un'accuratezza poco superiore al caso, s è prossima a zero e il limite superiore dell'errore diventa praticamente inutile. Manca quindi un segnale informativo di fondo che l'aggregazione di più alberi possa stabilizzare e valorizzare.

Per comprendere meglio come la complessità del modello influisca su questi risultati, la Figura 5.1 confronta i risultati ottenuti sui dati di addestramento con quelli di cross-validation al variare dei parametri impostati. Nel caso dell'Albero Decisionale (Figura 5.1a) si nota come aumentando la profondità della struttura il rendimento sul training set cresca dal 53% al 70%. Al contrario, l'accuratezza nella fase di verifica rimane attorno al 52% fino ad una profondità di 5, per poi scendere sotto il 50%. Questo fa intuire come il modello tenda a memorizzare il campione di addestramento perdendo capacità di generalizzare (Sezione 3.3) e spiega perchè la grid search seleziona una profondità ridotta. Diversamente, per la Random Forest (Figura 5.1b), l'aumento dell'insieme di alberi non porta alcun beneficio. L'accuratezza in cross-validation oscilla tra il 50.5% e il 51.5%, con barre d'errore che non permettono di distinguere le prestazioni dalla soglia di casualità (0.5). Questo è coerente con l'idea che l'aggregazione di alberi non è in grado di estrarre un segnale informativo assente nei dati. Si sceglie l'Albero Decisionale in quanto registra la balanced accuracy in cross-validation più alta, anche se di poco.



(a) Albero Decisionale

(b) Random Forest

Figura 5.1: Accuratezza in training e in cross-validation al variare di un iperparametro (profondità massima per l'Albero, numero di alberi per il Random Forest). Le barre indicano la deviazione standard tra i fold.

L'indice di importanza delle variabili (Sezione 3.6) non è riportata dato che le capacità predittive della foresta non superano il modello casuale, non permette di stabilire quali variabili siano rilevanti.

5.2 Valutazione sul Test Set

I risultati sul test set derivano da una singola valutazione eseguita sugli stint della stagione 2025 (336 a basso degrado e 275 ad alto degrado). Il modello non ha mai visto questi dati. Dato che il modello migliore è risultato essere il Decision Tree, anche se per poco, è su questo che si è concentrata la valutazione finale sul test set, con l'obiettivo di verificare se il lieve vantaggio rilevato in cross-validation si mantenga anche su nuovi dati.

La balanced accuracy ottenuta è pari a 0.462, inferiore sia al valore in cross-validation (0.522) sia alla soglia del caso (0.5). Per comprendere come il modello arriva a questo risultato conviene osservare la **matrice di confusione** (Figura 5.2). Le righe indicano la classe reale dello stint (degrado basso o alto) e le colonne la classe prevista. Gli elementi sulla diagonale principale corrispondono alle classificazioni corrette, mentre gli altri rappresentano gli errori. La matrice mostra che il modello prevede quasi sempre degrado basso. Tra gli stint a basso degrado ne riconosce correttamente 285 su 336 (84.8%), mentre tra quelli ad alto degrado ne riconosce solo 21 su 275 (7.6%). La balanced accuracy è la media di queste due percentuali, e per questo risulta pari a 0.462. In pratica, il modello non riesce a distinguere le due situazioni.

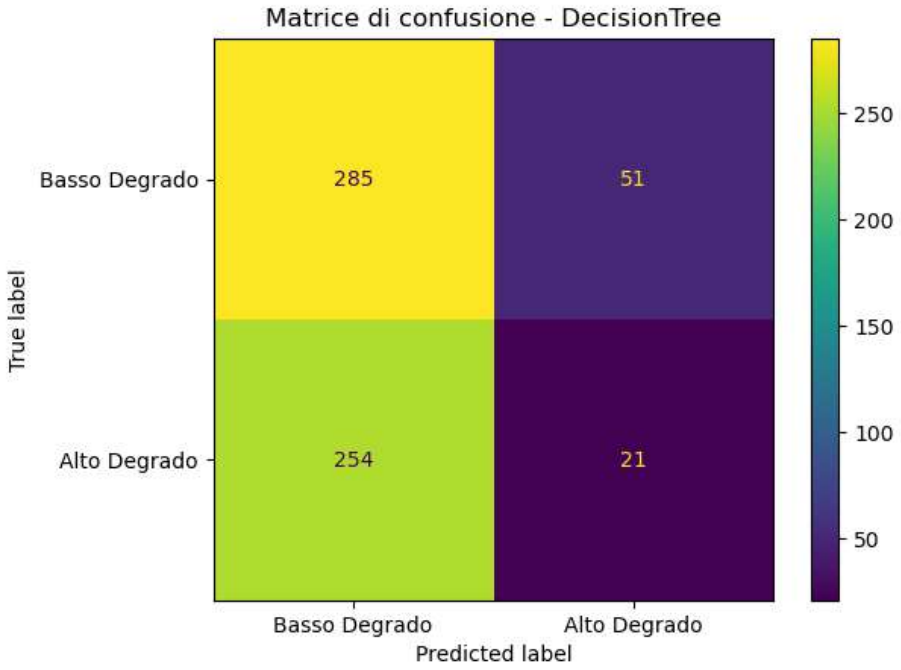


Figura 5.2: Matrice di Confusione.

Questo risultato deriva da un test set di sole 16 gare. Per valutarne la stabilità si ripete il calcolo 2000 volte su 16 gare estratte casualmente con reinserimento. Il 95% dei valori ottenuti è compreso tra 0.416 e 0.498, questo conferma che il risultato non è legato dalla particolare scelta delle gare.

Il Decision Tree non supera il caso nemmeno cambiando le gare. Per capire se lo stesso valga per gli altri modelli, i cui punteggi in cross-validation sono, comunque, di poco superiori al caso, si ricorre al **permutation test**. L'idea è testare ogni modello in una condizione in cui si sa per certo che non c'è nulla da imparare. Per farlo, si mantengono fisse le velocità degli stint, ma si mescolano casualmente i valori di degrado (alto o basso). In questo modo, il degrado assegnato non dipende più dalle velocità. Si ripete l'intero processo di addestramento per 100 volte, e si confrontano i punteggi ottenuti su dati con degrado mescolato con quelli registrati sul dataset reale. Questo confronto permette di verificare, per ciascun modello, se le prestazioni ottenute siano effettivamente

superiori a quelle di un'assegnazione casuale. Il risultato si valuta attraverso il **p-value**[1] che qui corrisponde alla proporzione delle 100 ripetizioni in cui il punteggio ottenuto con dati mescolati risulta almeno pari a quello reale. Un valore piccolo indica che un punteggio alto è raro quando il degrado è assegnato a caso. Per convenzione, un valore inferiore a 0.05 indica che il modello supera le prestazioni casuali.

Come mostra la Tabella 5.2, con il degrado mescolato tutti i modelli ottengono in media da 0.499 a 0.500, praticamente come nel dataset reale. Il p-value più basso è 0.188 per il Decision Tree, quindi in circa 19 ripetizioni su 100 il punteggio con degrado mescolato è almeno pari a quello reale. Nessun modello scende sotto la soglia, quindi per nessuno c'è evidenza che superi il caso.

Modello	Balanced accuracy	Media permutazioni	p-value
Regressione Logistica	0.500	0.499	0.426
kNN	0.505	0.499	0.277
Albero Decisionale	0.511	0.499	0.188
Random Forest	0.507	0.500	0.277

Tabella 5.2: Risultati del permutation test (100 permutazioni).

Il punteggio dell'Albero Decisionale (0.511) è inferiore a quello della Tabella 5.1 (0.522) perchè gli iperparametri vengono scelti di nuovo a ogni ripetizione. Per contenere i tempi di calcolo, la griglia della Random Forest è stata ridotta.

Dai dati e dai modelli analizzati non emerge una relazione tra velocità in qualifica e il degrado che permetta di prevederlo. A questo punto resta da capire il motivo.

5.3 Interpretazione dei risultati

I risultati della sezione precedente mostrano che le velocità registrate in qualifica non permettono di prevedere il degrado. Per capire a cosa sia dovuto, bisogna distinguere due possibilità: che il problema sia negli algoritmi oppure nei dati.

Tre elementi indicano che il problema non dipenda dall'algoritmo utilizzato. In primo luogo, quattro modelli di natura diversa, uno lineare e tre non lineari, ottengono tutti risultati vicini al caso. In secondo luogo, l'accuratezza in addestramento cresce fino al 70% mentre quella in cross-validation resta attorno al 50% (Figura 5.1), questo evidenzia una tendenza dei modelli più flessibili a memorizzare il rumore senza apprendere regolarità reali. Infine, l'assenza di un segnale predittivo emerge già nella cross-validation tra le stagioni 2022-2024, quindi non dipende dal fatto che il test sia la stagione 2025. Nel loro insieme, questi fattori suggeriscono che l'informazione utile nei dati sia assente o troppo debole per essere rilevata.

Se il problema è nei dati, si tratta di chiarire perchè l'informazione sia assente o troppo debole. A tal fine, si possono avanzare tre ipotesi, che non si escludono a vicenda.

Una prima ragione riguarda la quantità di informazione indipendente. Le velocità sono misurate in qualifica, quindi sono identiche per tutti gli stint dello stesso pilota nella stessa gara. I 2572

[1] Il p-value è la probabilità di ottenere un risultato almeno pari a quello osservato nel caso in cui non esista alcuna relazione tra le variabili.

stint analizzati nel dataset completo (senza esclusioni) corrispondono a 1200 combinazioni distinte di anno, gara e pilota. Questo rende più difficile individuare una relazione debole.

Il secondo aspetto riguarda il degrado. Essendo calcolato come la pendenza della retta sui tempi sul giro per ciascuno stint, questo parametro può risentire di fattori non descritti dalle velocità in qualifica, come il traffico in pista, la gestione degli pneumatici e le strategie di gara. Inoltre, la classificazione si basa sulla distanza dalla mediana. Due stint con un degrado quasi identico possono ricevere etichette opposte. Per questi stint la classe dipende da differenze molto piccole, e le velocità di qualifica non possono prevederle.

La terza riguarda l'uso di una proxy, che introduce un margine di errore: la stima del carico aerodinamico (non ricavabile in modo diretto dai dati pubblici) si basa sulle velocità allo *speed trap* e nei rilevamenti intermedi. Tuttavia, questi valori dipendono anche da altri fattori (potenza, DRS[2], effetto scia, stato della pista), che si sommano al segnale del carico aerodinamico, rendendolo difficile da isolare.

Con questi presupposti, è difficile che un algoritmo riesca a isolare un segnale. Algoritmi differenti restituiscono risultati vicini al caso. Questo non esclude che un segnale esista, ma potrebbe essere troppo debole per emergere con questi dati.

[2] *Drag Reduction System* o sistema di riduzione della resistenza aerodinamica.

Capitolo 6

Conclusioni

6.1 Sintesi dei risultati

L'obiettivo di questo studio è verificare se le velocità misurate in qualifica, usate come indicatore del carico aerodinamico, permettono di prevedere se uno stint di gara avrà un degrado delle gomme superiore o inferiore alla mediana del proprio circuito e della propria mescola. Il problema è impostato come classificazione binaria a livello di stint, usando i dati delle stagioni 2022-2025 e confrontando un modello lineare (Logistic Regression) con tre modelli non lineari (kNN, Decision Tree, Random Forest).

Con i dati e i modelli considerati, non si osserva un segnale utile alla previsione. Nella cross-validation per stagione (2022-2024), i modelli non vanno oltre una balanced accuracy di 0.522, con un minimo di 0.507. Il modello scelto, l'Albero Decisionale, sul 2025 ottiene 0.462, peggio della baseline, e il suo intervallo di confidenza sulle gare (da 0.416 a 0.498) non include nemmeno 0.5. Il permutation test conferma questo risultato: nessun modello ottiene prestazioni distinguibili di quelle di un'assegnazione casuale del degrado, con p-value compresi tra 0.188 e 0.426.

Il risultato è coerente con l'analisi teorica del Capitolo 3. La Random Forest riduce la varianza rispetto al singolo albero, ma il suo errore di generalizzazione dipende anche dalla forza s dei singoli alberi. Se gli alberi sono poco migliori del caso, s è vicina a zero e il limite superiore all'errore resta alto, indipendentemente da quanto sia bassa la correlazione tra gli alberi. In questo caso l'aggregazione non ha segnale informativo da stabilizzare, per questo la Random Forest non supera il Decision Tree. Lo stesso vale per l'importanza delle variabili, su un modello che non supera il caso, non avrebbe un'interpretazione affidabile.

Dal punto di vista fisico, il legame atteso è plausibile. Un maggiore carico aerodinamico incrementa il carico verticale sulle gomme, e quindi la loro sollecitazione meccanica, con maggiore riscaldamento e usura. Poichè un carico maggiore comporta anche più resistenza all'avanzamento, le velocità di qualifica possono essere considerate un proxy ragionevole. Il risultato non cancella il legame fisico: la velocità è una misura indiretta del carico, perchè dipende anche da potenza, DRS e scia. Inoltre, tra qualifica e gara intervengono variabili che i dati pubblici non descrivono.

I dati confermano che la velocità in qualifica, da sola, non basta a spiegare il legame tra carico aerodinamico e degrado.

6.2 Sviluppi futuri

L'analisi condotta lascia aperte alcune questioni, che possono costruire la base per sviluppi futuri.

Una prima opzione riguarda la variabile target. Si potrebbe stimare il degrado direttamente come variabile continua tramite regressione, ma cambiando toltalmente l'idea di classificazione. In alternativa, si potrebbero escludere i valori vicini alla soglia, concentrandosi solo sugli estremi.

Una seconda possibilità riguarda l'approssimazione del carico aerodinamico. La velocità in curva, ricavabile dalla telemetria, risente meno della potenza e del DRS rispetto alla velocità sul rettilineo.

Si potrebbero aggiungere al dataset variabili come la temperatura dell'asfalto e il traffico.

In ogni caso, i risultati ottenuti dimostrano che la sola velocità in qualifica non basta a prevedere il degrado, rendendo necessarie informazioni più approfondite.

Bibliografia

[1] Leo Breiman. Random forest. *Machine Learning*, 2001.

[2] Nicolas de Condorcet. Essai sur l'application de l'analyse à la probabilité des décisions rendues à la pluralité des voix, 1785.

[3] Darien. Will cfd technology shape the next era of f1 aerodynamics? `https://medium.com/@darienjy5056/will-cfd-technology-shape-the-next-era-of-f1-aerodynamics-6b39b9a3820b`, 2025. Consultato il 6 ottobre 2026.

[4] Fédération Internationale de l'Automobile (FIA). 2022 Formula 1 Financial Regulations. Official FIA Regulation, 2022. Issue 13.

[5] Fédération Internationale de l'Automobile (FIA). 2022 Formula 1 Sporting Regulations. Official FIA Regulation, 2022. Issue 9.

[6] Fédération Internationale de l'Automobile (FIA). 2022 Formula 1 Technical Regulations. Official FIA Regulation, 2022. Issue 13.

[7] Travor Hastie, Robert Tibshirani, and Jerome Friedman. *The Elements of Statistical Learning*. Springer, 2017.

[8] Bhavin Lathia. Anatomy of an f1 car: Every main part, and what it really does, 2026.

[9] William F. Milliken and Douglas L. Milliken. *Race Car Vehicle Dynamics*. SAE International, 1995.

[10] Adrian Newey. *How to build a car*. HarperCollinsPublishers, 2017.

[11] Örjan Oostdijk and contributors. Fastf1: Python library for accessing formula 1 timing data and telemetry, 2020.

[12] Pirelli. Pirelli formula 1: gamma degli pneumatici. `https://www.pirelli.com/tyres/en-ww/motorsport/f1`.

[13] Lorenzo Rosasco. Some basic ideas in machine learning, 2026.

[14] themotorsportmetrics. Fuel load and lap time explained: The powerful math behind faster race pace, 2026.

[15] Giovanni Tito. F1 – pirelli vuole essere più aggressiva nel futuro. https://www.formulacritica.it/news/260107046406/f1-vedremo-le-pirelli-pi-aggressive-per-il-futuro, 2026.

[16] umakshually. Fuel correction, 2024.

[17] Simone Valtieri. Che cos'è il graining? - dizionario della formula 1. https://www.motorbox.com/auto/sport/f1/news/dizionario-f1-che-cose-il-graining, 2022.